

C 阶段冻结 ASAP 测试实验报告

P3、P4-R 与 P4-L 的参考谱符号一致性评估

钢琴转录项目

2026 年 8 月 18 日

结论摘要：冻结评测在 120 条演奏、31 首作品上完成 360/360 个系统输出，零失败。三条管线的 pitch/onset 结果几乎相同；P4-L 的事件微平均 note F1 与时值正确率最高，但以作品为配对单位的 bootstrap 下，其相对 P3 的优势均未得到 95% CI 支持。P4-R 在 tie 与 voice 一致性上呈现稳定优势。

1 评测目的与证据边界

本报告给出 C 阶段的**最终 MusicXML 相对冻结 ASAP 参考谱的符号一致性**结果。它回答的是“系统导出的整谱，在符号层面与人工参考谱有多接近”，不回答候选排序器本身是否有效，也不回答量化 MIDI 到 MusicXML 的导出是否忠实。

因此，以下三类证据严格分开解释：

- **候选级排序质量：**历史 LightGBM 的 ROC-AUC=0.868960、AP=0.857762、Top-1=0.738746（规则基线 Top-1=0.625078）。这是候选排序的证据，不能与本报告的整谱指标相加或换算。
- **B 阶段导出忠实性：**评估 MIDI 量化输入到 XML 输出的结构对账；它不是参考谱比较，不能替代本报告。
- **C 阶段参考谱一致性：**本报告的对象。它使用冻结 ASAP test 参考 MusicXML，比较最终导出的谱面符号。

2 冻结设置与完整性核验

P4-L 使用的冻结候选模型为 p4_asap_cross_piece_v1；模型文本与元数据的 SHA-256 分别为 31f58c...7b666 与 7dbead...c6fe6。运行目录保留配置、冻结 manifest、模型副本与校验和、命令审计日志、逐项 MusicXML/metrics，以及逐演奏、逐作品和总汇总文件，形成可复核证据包。

3 指标与统计方法

事件匹配。 预测和参考事件按一对一最小代价贪婪匹配。pitch 要求同手与同音高；onset 进一步要求起音误差不超过 0.125 QL；note 进一步要求时值误差不超过 0.25 QL。duration 在 onset 成功匹配的事件上评估。对齐有效区间外的系统事件单独作为 coverage 处理，不伪装为普通匹配错误。

表 1: 冻结评测设置与资产核验

项目	设置 / 结果
测试集	ASAP test: 120 条演奏、31 首作品；作品为宏平均和配对重采样的统计单位
系统	P3、P4-R、P4-L
运行总量	$120 \times 3 = 360$ 个 (演奏, 系统) 输出
完成情况	360/360 完成; 0 条演奏含任一系统失败; 无 <code>failures.csv</code>
对齐	复用独立于系统输出的 ASAP 演奏-参考谱对齐 CSV; 未从 P3/P4 输出重建或选择对齐
时值格点	divisors=8,4,3; 最多 12 个声部
容差	$\text{onset} \leq 0.125 \text{ QL}$; $\text{duration} \leq 0.25 \text{ QL}$; $\text{pedal} \leq 0.25 \text{ QL}$
统计	作品等权宏平均; 事件汇总微平均; 1,000 次 paired bootstrap, seed=20260817
P4-L 溯源	冻结模型文件 SHA-256 已核验; 120/120 项均在审计日志中确认加载 LightGBM, 未发现规则评分回退

符号语义。 tie 以 tie-chain 语义计分。voice 不直接比较 MusicXML 原始编号, 而以系统 voice 映射到参考 voice 的多数类纯度衡量, 以消除编号置换造成的伪差异。相同时点的 pedal stop+start 规范为 change。

两种汇总。 作品宏平均先在同一作品的多条演奏内聚合, 再对 31 首作品等权平均; 它是本报告主要比较口径。事件微平均则从全体事件 TP/预测数/参考数或正确数/匹配数重新计算, 会使事件较多的演奏权重更大。报告二者, 避免以一个替代另一个。

4 主要结果：作品等权宏平均

表 2: 31 首作品等权宏平均 (高者更好; Duration MAE 低者更好)

指标	P3	P4-R	P4-L
Pitch F1	0.662274	0.662273	0.662273
Onset F1	0.660684	0.660684	0.660684
Note F1	0.399564	0.373617	0.386087
Duration accuracy	0.590685	0.560802	0.591500
Tie accuracy ^a	0.331496	0.534950	0.376042
Voice accuracy	0.538052	0.611472	0.579449
Pedal F1 ^b	0.002216	0.002336	0.001698
Duration MAE (QL)	0.350600	0.397249	0.350542

^a 仅 29 首作品有可用 tie 指标。^b 仅 7 首作品有可用 pedal 指标, 且绝对值很低。

宏平均下, P3 的 note F1 为 0.399564, 高于 P4-L (0.386087) 和 P4-R (0.373617)。P4-L 的时值正确率 (0.591500) 及 duration MAE (0.350542 QL) 略优于 P3; P4-R 则在 tie 和 voice 上最

高。三管线的 pitch/onset 几乎一致，说明差异主要落在时值、tie-chain 与声部决策，而不是本研究的音高或起音匹配层。

5 补充结果：事件汇总微平均

表 3: 120 条演奏的事件微平均			
指标	P3	P4-R	P4-L
Pitch F1	0.655314	0.655314	0.655314
Onset F1	0.652351	0.652351	0.652351
Note F1	0.420610	0.417104	0.441057
Duration accuracy	0.644361	0.638879	0.675225
Tie accuracy	0.325070	0.537071	0.354727
Voice accuracy	0.539307	0.587400	0.555315
Pedal F1	0.002207	0.002295	0.001809

微平均在事件量较大的演奏上改变了权重：P4-L 的 note F1 为 0.441057，高于 P3 的 0.420610，且时值正确率为 0.675225。这与作品宏平均的 note F1 排序不同，正是报告两种口径的原因；不能从微平均单独推导“所有作品均获益”。

6 作品层分布与不确定性

表 4: 作品层主要指标分布：中位数 [Q1, Q3]				
指标	统计量	P3	P4-R	P4-L
Note F1	median [Q1,Q3]	0.386 [0.152,0.641]	0.307 [0.158,0.609]	0.276 [0.182,0.607]
Duration acc.	median [Q1,Q3]	0.616 [0.462,0.724]	0.601 [0.456,0.714]	0.640 [0.469,0.739]
Tie acc. ^a	median [Q1,Q3]	0.377 [0.142,0.500]	0.600 [0.312,0.704]	0.354 [0.300,0.415]
Voice acc.	median [Q1,Q3]	0.486 [0.430,0.649]	0.624 [0.509,0.728]	0.590 [0.489,0.699]

^a29 首有可用 tie 指标。

作品间异质性明显。例如 P3 的 note F1 范围为 0.032–0.854，P4-R 为 0.029–0.897，P4-L 为 0.034–0.883。因此，均值差异必须配合按作品配对的 bootstrap 区间阅读。

7 受统计支持的解释

- **P4-R 的结构性优势集中在 tie 与 voice。**相对 P3，P4-R 的 tie accuracy 差值为 +0.203454 (95% CI [+0.148012, +0.260277])，voice accuracy 为 +0.073420 ([+0.053768, +0.094161])；两者区间均不跨零。

表 5: 配对 bootstrap: 观察到的作品均值差 (A-B) 及 95% CI

指标	比较	配对作品数	差值	95% CI
Note F1	P4-L - P4-R	31	+0.012470	[-0.018513, +0.041865]
	P4-L - P3	31	-0.013477	[-0.050506, +0.023496]
	P4-R - P3	31	-0.025947	[-0.050247, -0.006162]
Duration acc.	P4-L - P4-R	31	+0.030699	[-0.016888, +0.080394]
	P4-L - P3	31	+0.000816	[-0.050778, +0.052795]
	P4-R - P3	31	-0.029883	[-0.054262, -0.009713]
Tie acc.	P4-L - P4-R	29	-0.158909	[-0.264621, -0.040519]
	P4-L - P3	29	+0.044546	[-0.057797, +0.157235]
	P4-R - P3	29	+0.203454	[+0.148012, +0.260277]
Voice acc.	P4-L - P4-R	31	-0.032023	[-0.054232, -0.014275]
	P4-L - P3	31	+0.041397	[+0.013056, +0.070065]
	P4-R - P3	31	+0.073420	[+0.053768, +0.094161]

- **P4-L 未显示相对 P3 的全局 note/timing 优势。** P4-L 相对 P3 的 note F1 差值为 -0.013477 ([-0.050506, +0.023496]), duration accuracy 为 +0.000816 ([-0.050778, +0.052795]); 二者均跨零。
- **P4-L 相对 P4-R 的时值优势尚不确定, 声部/tie 劣势更稳定。** 前者 duration accuracy 的区间跨零; 后者在 tie (-0.158909, [-0.264621, -0.040519]) 与 voice (-0.032023, [-0.054232, -0.014275]) 上均不利。
- **踏板结论不能强化。** 可配对作品仅 7 首, 三种比较的 pedal F1 区间均跨零, 且 F1 约为 0.002 量级。

8 局限与后续纪律

- 该结果的外推对象是冻结 ASAP test 上的参考谱符号一致性, 不等于主观可读性、演奏表达质量或 B 阶段的导出忠实性。
- pitch/onset 在三管线间几乎恒定, 故本报告不支持关于候选评分函数改变音高/起音识别能力的论断。
- tie 与 pedal 的可作品数分别为 29 与 7; 特别是 pedal 的统计功效与绝对指标水平均有限。
- 冻结 test 已用于本次一次性结论性评估。任何后续模型、规则或阈值改进必须回到 train/valid 集设计与选择, 再以新的、预先约定的流程评估; 不得使用本报告的 test 指标作调参信号。

9 复核入口

冻结证据目录: evals/C/frozen_test_20260817/。其中 config.json 固化评测参数与模型哈希, commands.log 保存导出审计, pieces/ 保存逐项输出与指标, summary/performance_level.csv、

`summary/piece_level.csv` 与 `summary/aggregate_summary.json` 分别保存逐演奏、逐作品与总汇总结果。