

C 阶段冻结踏板消融实验报告

P4 多声部记谱系统：CC64 信息的严格配对消融

冻结证据包：120 个演奏、31 首作品、4 条 P4 管线，共 480 个导出-评分组合；
逐曲配对 bootstrap (1,000 次, seed=20260817)。

1 目的与结论边界

本实验检验 MIDI CC64 踏板信息在 P4 后端中的作用。它衡量的是**生成 MusicXML 相对 ASAP 参考谱的符号一致性**，不衡量音频转 MIDI 前端误差，也不替代候选级排序指标或 B 阶段的导出忠实性。

结果表明：在本冻结集和当前量化/候选设计下，规则评分 (P4-R) 有无 CC64 的音符、时值、连音与声部指标**完全一致**；冻结 LightGBM (P4-L) 下，禁用 CC64 后的 note F1、时值准确率、tie 与 voice 指标均出现极小的数值上升，但所有相应 95% 配对 bootstrap 区间均跨越 0。因而，**不能据此声称 CC64 为当前参考谱一致性带来了可检出的正向增益**。与此同时，有踏板管线确实输出了踏板标记，而无踏板条件严格输出零个 `<pedal>` 元素；踏板 F1 的绝对值极低，说明当前 MIDI CC64 与参考谱踏板标记之间存在显著语义/标注粒度错配，不能把该结果包装成踏板记谱质量的正面证据。

2 实验设计

2.1 冻结资产与评价协议

- 冻结测试集：120 个演奏，31 首作品；统计宏平均的基本单位为**作品**。
- 输入、参考谱、外部对齐、量化参数、手部分配、最大声部数、容差及随机种子在四条管线间固定。
- 容差：onset ≤ 0.125 QL, duration ≤ 0.25 QL, pedal ≤ 0.25 QL。
- note/pitch/onset 使用同手、同 MIDI pitch 的事件匹配；tie 使用 tie-chain 语义；voice 使用映射后的多数类纯度。
- 置信区间：按作品进行有放回配对重采样，1,000 次，seed=20260817，报告 A-B 的均值差及 95% 区间。

2.2 四条管线与干预定义

管线	候选评分	CC64 处理
P4-R	规则评分	进入声学时值、候选特征/排序，并输出 pedal
P4-R-NP	规则评分	解码器传入空 CC64 区间；不输出 pedal
P4-L	冻结 LightGBM	同 P4-R 的 CC64 使用方式
P4-L-NP	冻结 LightGBM	同 P4-R-NP 的严格 CC64 禁用方式

无踏板并非事后删除 XML 标签：它在解码前向 `decode_score_hands` 传入空踏板区间，因此真实 CC64 不参与声学时值、候选生成、候选特征或规则/LightGBM 排序；同时不写出 MusicXML `pedal`。主要配对比较为 P4-R-P4-R-NP 与 P4-L-P4-L-NP；P4-L-P4-R 仅用于比较冻结学习评分与规则评分。

3 证据包完整性核验

核验项	结果
完成的 <code>metrics.json</code> 记录	480 / 480
每条管线完成数	120（四条管线均齐全）
覆盖作品数 / 演奏数	31 / 120
导出或评分失败数	0
P4-L、P4-L-NP 的 LightGBM 回退记录	0
无踏板 XML 中含 <code><pedal></code> 的文件	0 / 240
冻结 LightGBM 文本/JSON SHA-256	均与配置记录一致
历史 C 阶段基线目录	保持为独立目录，未被本运行覆盖

运行配置固定为 `divisors=8,4,3`, `max voices=12`。冻结候选模型文本/JSON 的 SHA-256 均与配置记录一致。`commands.log` 中未观察到“候选模型不可用，回退规则评分”；无踏板输出的命令级审计与 LightGBM 加载审计均覆盖恢复运行产生的全部相关导出记录。

4 主要结果：作品宏平均

管线	note F1	时值准确率	tie 准确率	voice 准确率	pedal F1
P4-R	0.3736	0.5608	0.5350	0.6115	0.00234
P4-R-NP	0.3736	0.5608	0.5350	0.6115	0.00000
P4-L	0.3861	0.5915	0.3760	0.5794	0.00170
P4-L-NP	0.3871	0.5932	0.3766	0.5801	0.00000

Pitch F1 与 onset F1 在同一候选评分条件下不受干预影响（P4-R: 0.6623 / 0.6607；P4-L: 0.6623 / 0.6607），符合本消融只作用于时值相关信息流的预期。事件 micro 平均也呈现相同格局：P4-R 的 note F1 为 0.4171，P4-L 为 0.4411，P4-L-NP 为 0.4416；但论文中的显著性判断应以预先定义的逐曲配对统计为准。

5 配对 bootstrap：主比较

配对	指标	A-B 均值差	95% CI	解释
P4-R-P4-R-NP	note F1	0.00000	[0.00000, 0.00000]	完全相同
	时值准确率	0.00000	[0.00000, 0.00000]	完全相同
	tie 准确率	0.00000	[0.00000, 0.00000]	完全相同
	voice 准确率	0.00000	[0.00000, 0.00000]	完全相同
P4-L-P4-L-NP	note F1	-0.00099	[-0.00210, 0.00006]	CI 跨 0
	时值准确率	-0.00171	[-0.00417, 0.00092]	CI 跨 0
	tie 准确率	-0.00053	[-0.00505, 0.00349]	CI 跨 0
	voice 准确率	-0.00066	[-0.00185, 0.00039]	CI 跨 0

有踏板相对无踏板的 pedal F1 差异为 P4-R: +0.00234, 95% CI [0.00056, 0.00492]; P4-L: +0.00170, 95% CI [0.00028, 0.00341]。这只说明有踏板条件产生了极少量与参考 pedal 标记匹配的事件; 由于绝对 F1 极低, 不能将其解释为可靠的踏板记谱性能。

6 补充比较：冻结学习评分与规则评分

P4-L 相对 P4-R 的逐曲宏平均差为: note F1 +0.01247 (95% CI [-0.01766, 0.04268]), 时值准确率 +0.03070 ([-0.01505, 0.07868]), tie 准确率 -0.15891 ([-0.26732, -0.02817]), voice 准确率 -0.03202 ([-0.05384, -0.01269])。因此, 学习评分在此冻结测试上呈现更高的时值点估计, 但其 note F1 / 时值区间仍跨 0, 且 tie 与 voice 存在稳定下降; 不应使用单一总体分数宣称全面优于规则评分。

7 可用于论文的表述与限制

7.1 可成立的陈述

- 已完成可复核的严格 CC64 配对消融: 无踏板条件在解码前屏蔽 CC64, 且 XML 层零踏板输出。
- 在 120 演奏、31 作品的冻结 ASAP 测试上, 当前 CC64 使用方式未显示出对 note F1、时值、tie 或 voice 一致性的可检出正向提升。
- 结果揭示了一个重要的负结果: performance MIDI 的 CC64 与参考谱中的 pedal 标记并非可直接互换的监督目标。

7.2 不可成立的陈述

- 不可声称当前系统已经获得高质量或高保真的踏板记谱; pedal F1 约为 0.002, 证据明确不足。
- 不可把本 C 阶段结果外推为端到端音频转录质量, 也不可替代候选级 LightGBM 排序评估。
- 不可仅凭 P4-L 的较高点估计宣称其全面优于规则评分; 关键指标存在区间跨 0, tie/voice 则显著更低。

8 下一步建议

当前最有价值的推进不是继续强调 CC64 的平均增益，而是构建 30–50 个片段的踏板专用人工金标准：明确区分延音声学证据、演奏踏板动作与出版谱踏板标记，并对 retake/change、半踏与编辑性省略建立标注规则。随后在该金标准上重测 pedal event、延音时值及可读性，才能把踏板模块从“已实现、已严格消融”推进到“具有可辩护效果”的论文证据。

证据位置：evals/C/pedal_ablation_frozen_20260818/。核心文件：config.json、manifest/、models/、commands.log、summary/aggregate_summary.json、summary/performance_level.csv、summary/piece_level.csv。